

# Neural Network Applied to Classification of Arm and Forearm Movement Intent

L. A. M. Castro, G. S. Amorim, B. G. Dutra and A. S. Silveira

**Abstract**— The myoelectric signals are electrical potentials that represent the dynamics of muscle contraction and its study has shown to be relevant in applications in physiotherapy and rehabilitation for improvement of the quality of life of amputated individuals or with some type of motor deficiency. The paper proposes a neural classifier that consists of two neural networks in parallel, constructed with the aid of the computational tool MATLAB®, to identify the intention of arm and forearm movement, being able to be used as command source for myoelectric prostheses and robotic arms. Numerical simulations prove the efficacy of the developed neural classifier.

**Index Terms**— Myoelectric Signals, Neural Networks, Biomedical Applications.

## I. INTRODUÇÃO

DIARIAMENTE, (o comportamento da atividade elétrica muscular é um aspecto relevante em diversos processos corpóreos e seu estudo é essencial nos mais variados ramos, como o esportivo, de reabilitação, fisioterapêutico e afins. Os sinais mioelétricos (SMEs) são potenciais de ação que percorrem a membrana celular das fibras musculares, ocasionando sua contração [1]. A análise e o processamento desses sinais possibilitam a sua associação com seu respectivo movimento. Diversas pesquisas científicas envolvendo o reconhecimento e classificação de SMEs vem sendo desenvolvidas em aplicações para o controle de próteses, objetivando a reabilitação e melhoria da qualidade de vida de indivíduos amputados ou com algum acometimento motor.

Um grande desafio encontrado por pesquisadores na área de controle de SMEs é conseguir reconhecer um padrão no sinal, extrair características, processar em tempo real e alcançar um desempenho mais natural possível para a prótese. Isso se deve à ampla variação das características da onda mioelétrica, que dependem de variáveis como idade, sexo, atividade muscular, camada de gordura na pele, tipo de unidade motora e movimento [2]. Além disso, o sinal eletromiográfico superficial apresenta vários tipos de ruídos

causados por fontes eletromagnéticas, grupos musculares adjacentes, mau contato entre o eletrodo (sensor) e a pele, ruído inerente do equipamento e do ambiente. Assim, muitas pesquisas estão sendo feitas com propostas de classificadores mais precisos e eficazes, capazes de atuar de maneira universal, principalmente em amputados, nos quais os grupos musculares remanescentes foram alterados.

Neste contexto, o uso de Redes Neurais Artificiais (RNAs) tem se mostrado bastante promissor, conseguindo identificar e classificar séries de movimentos humanos a partir do SME. Em [3] e [4], os autores conseguiram 95% e 98% de eficiência na classificação dos padrões de movimentos da mão e do braço, respectivamente. Entretanto, muitas literaturas alcançam um alto desempenho fazendo uso de muitas unidades de aprendizagem (neurônios) e/ou camadas, fator esse que demanda um elevado nível computacional e tempo de processamento. Com isso, a aplicação em tempo real de topologias mais densas e complexas é dificultada, já que a resposta de todo o sistema de aquisição, processamento, classificação e controle deve estar em uma faixa de 50 ms a 400 ms [5].

O objetivo deste trabalho é desenvolver um classificador a partir de duas RNAs independentes e em paralelo, para o reconhecimento de quatro padrões de intenção do movimento do antebraço e mão: extensão/flexão do antebraço e adução/abdução dos dedos, adquiridos a partir de dois canais posicionados nos músculos responsáveis pelos respectivos movimentos. As respostas geradas por cada rede são combinadas para a criação de um sinal de referência, que pode ser usado como entrada em uma malha de controle.

O artigo está dividido em: na seção 2 explana-se sobre os SMEs e seu pré-processamento; na seção 3 é exposta a teoria de redes neurais artificiais; a etapa de treinamento e validação das redes neurais candidatas é feita na seção 4; os resultados da topologia da rede neural selecionada são discutidos na seção 5 e, por fim, as conclusões são apresentadas na seção 6.

## II. SINAL MIOELÉTRICO

O sinal mioelétrico (SME) ou eletromiográfico é um potencial de ação que tem duração de 1 a 5 ms e percorre a superfície das fibras musculares, induzindo a liberação de íons cálcio pelo retículo sarcoplasmático, possibilitando o deslizamento dos filamentos de actina sobre o de miosina, ou seja, a contração muscular [6]. Na verdade, os SMEs são resultados da atividade elétrica de unidades motoras. A unidade motora é o conjunto de fibras musculares inervadas pela mesma fibra nervosa, incluindo a sua junção neuromuscular [6], [7]. Quando um potencial de ação chega ao músculo, suas unidades motoras são excitadas e, o somatório

Manuscrito submetido em 2 de fevereiro de 2018. Este trabalho possui apoio de instituições de fomento e incentivo à pesquisa no Brasil CAPES e CNPq.

L. A. M. Castro é vinculado à Universidade Federal do Pará, Belém, Brasil, (e-mail: luismesquita@ufpa.br).

G. S. Amorim é vinculada à Universidade Federal do Pará, Belém, Brasil, (e-mail: gaby\_amorim@outlook.com).

B. G. Dutra é vinculado à Universidade Federal do Pará, Belém, Brasil, (e-mail: brunodutra@ufpa.br).

A. S. Silveira é vinculado à Universidade Federal do Pará, Belém, Brasil, (e-mail: asilveira@ufpa.br).

do potencial das  $n$  fibras musculares de cada unidade motora origina o chamado potencial de ação da unidade motora (MUAP – *Motor Unit Action Potential*). E o SME é composto pela junção desses diversos MUAPs em cada músculo [8].

#### A. Aquisição dos sinais musculares

A captura dos SMEs é feita por meio de sensores conhecidos como eletrodos. Os eletrodos possuem, basicamente, duas classes: os invasivos ou de agulha e os não invasivos ou de superfície. A quantidade de eletrodos empregados para uma medição varia de acordo com a sua configuração, podendo ser monopolar, bipolar ou multipolar.

Neste estudo, são empregados dois pares bipolares de eletrodos superficiais posicionados no grupo muscular responsável por cada movimento. Então, foram utilizados dois canais de aquisição, um canal no braço para o músculo Bíceps e outro no antebraço para o músculo Flexor Superficial dos Dedos. O SME apresenta componentes frequenciais que se concentram na faixa de 50 Hz a 150 Hz, com amplitude entre 50  $\mu$ V e 5 mV, dependendo do músculo. O SME sofre interferência de muitos ruídos advindos de múltiplas fontes, como a indução eletromagnética provocada pela rede elétrica na faixa de 60 Hz; ruídos comuns dos eletrodos com a superfície da pele; de artefatos em movimento ou até mesmo de instabilidades do próprio sinal [1,8].

Sendo assim, após os sinais serem obtidos é necessária uma etapa de tratamento. O SME é aquisitado com período de amostragem ( $T_s = 2$  ms), amplificado, filtrado, retificado e suavizado pela placa de circuito integrado Muscle Sensor V3, sendo transmitido para um Arduino Nano para que seja feita sua conversão A/D de 8 bits. O Arduino Nano faz a interface entre computador e mundo físico via porta USB, os dados são armazenados na memória do computador para a criação de um banco de dados de cada movimento e consequente extração das características temporais do sinal.

#### B. Extração de características

Na literatura é comum encontrar a extração de características dos sinais mioelétricos. Devido o SME ser relativamente extenso e complexo, o cálculo dessas características reduziria o vetor de entrada e aumentaria o desempenho do classificador. Em [9] os autores citam características no domínio do tempo e da frequência, como a média dos valores absolutos (MAV – *Mean Absolute Value*), cruzamento com zero (ZC – *Zero Crossing*), alterações no sinal da inclinação (SSC – *Slope Sign Changes*), comprimento de forma de onda (WL – *Waveform Length*) e outros. Algumas características conseguem melhor representar os sinais do que outras, e certos trabalhos já avaliaram o desempenho da rede neural para diferentes possíveis combinações dessas características. Por exemplo, o MAV e o WL estão entre os melhores parâmetros para caracterizar o sinal muscular [10].

Neste trabalho, foram extraídas apenas duas características do sinal, o MAV e o WL. Ambas as características foram

calculadas a cada 10 amostras do sinal e armazenadas em um vetor, posteriormente usado como entrada da RNA. O MAV e WL são calculados como:

$$MAV = \frac{1}{S} \sum_{k=1}^S |x(k)| \quad (1)$$

$$WL = \sum_{k=1}^S |x(k) - x(k-1)| \quad (2)$$

onde  $x(k)$  representa o valor da amplitude do sinal no instante de tempo  $k$  e  $x(k-1)$  o valor da amplitude do sinal no instante de tempo  $k-1$ . A variável  $S$  é o número total de amostras da janela.

Cada conjunto de sinais mioelétricos equivalentes a um tipo de movimento é transformado em um vetor de características. O tamanho dos vetores varia conforme o número de amostras adquiridas durante a execução de tal movimento. Tais vetores de características são armazenados em um banco de dados, o qual é utilizado para o treinamento e validação do classificador neural.

### III. REDES NEURAIS ARTIFICIAIS

RNA é o acrônimo em língua portuguesa para Redes Neurais Artificiais, as quais são modelos computacionais, inspirados nos neurônios biológicos e na estrutura do cérebro, com capacidade de adquirir, armazenar e utilizar conhecimento experimental [11]. As RNAs são utilizadas nas mais diversas aplicações humanas [12,13,14]. Nesse trabalho serão utilizadas as redes *Perceptron* multicamadas (PMC), as quais são caracterizadas pela presença de pelo menos uma camada intermediária (escondida) de neurônios, localizada entre a camada de entrada a respectiva camada neural de saída. Portanto, as redes PMC possuem no mínimo duas camadas de neurônios, os quais estão distribuídos nas camadas escondidas e a camada de saída da rede.

As redes PMC são caracterizadas pelas elevadas possibilidades de aplicações em diversas problemáticas de várias áreas do conhecimento. As redes PMC também são consideradas uma das arquiteturas de redes mais versáteis quanto à aplicabilidade, tais redes são utilizadas nas seguintes áreas [15]: aproximação universal de funções; reconhecimento de padrões; identificação e controle de processos; previsão de séries temporais e otimização de sistemas.

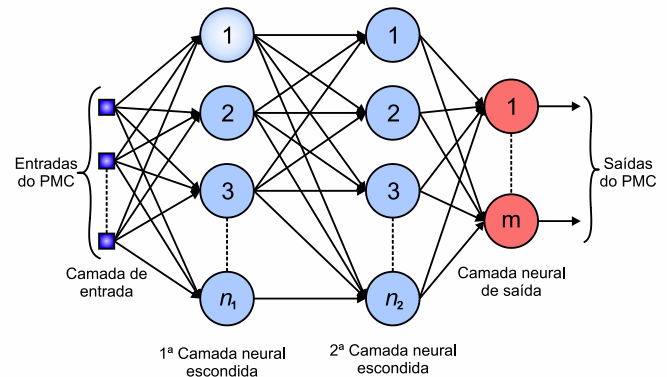


Fig. 1. Rede *Perceptron* multicamadas.

A rede PMC pertence à arquitetura *feedforward* de múltiplas camadas, cujo treinamento é realizado de forma

supervisionada. Conforme observado na Fig. 1, o fluxo de informações na estrutura da rede se inicia na camada de entrada da rede, percorre em seguida as camadas escondidas, sendo finalizado na camada de saída da rede. Observa-se ainda que na rede PMC convencional, não existe qualquer realimentação das saídas produzidas pela rede, tanto da camada de saída quanto das camadas escondidas [16].

Por intermédio da Fig. 1, nota-se que cada uma das entradas da rede, representando os sinais advindos de determinada aplicação, será propagada uma a uma em direção à camada neural de saída do PMC. Nessa situação, as saídas dos neurônios da primeira camada neural escondida serão entradas para os neurônios pertencentes à segunda camada escondida e assim sucessivamente, ou seja, as saídas de uma camada escondida serão as entradas para a camada escondida imediatamente posterior. Para a situação apresentada na Fig. 1, as saídas dos neurônios da segunda camada neural escondida serão as respectivas entradas dos neurônios pertencentes à camada de saída da rede neural. Dessa forma, a propagação dos sinais de entrada da rede PMC, independentemente de quantidade de camadas escondidas, é sempre efetuada em um único sentido, ou seja, da camada de entrada em direção à camada de saída da rede [11].

Na rede PMC o mapeamento integral de todo o processo, o conhecimento relacionado ao comportamento entrada/saída do sistema é distribuído por todos os neurônios constituintes da rede PMC. Os estímulos ou sinais são apresentados à rede em sua camada de entrada. As camadas escondidas, por sua vez, extraem a maioria das informações referentes ao seu comportamento e as codificam por meio dos pesos sinápticos e limiares de seus neurônios, formando assim uma representação própria do ambiente em que está inserido o referido sistema a ser tratado. Finalmente, os neurônios da camada de saída recebem os estímulos provenientes dos neurônios da última camada escondida, produzindo um padrão de resposta que é a saída disponibilizada pela rede neural [15].

O ajuste dos pesos e do limiar de cada um dos neurônios da rede PMC é executado utilizando-se o processo de treinamento supervisionado, isto é, para cada amostra dos dados de entrada obtém-se a respectiva saída (resposta) desejada. O algoritmo de aprendizado aplicado no decorrer do processo de treinamento de redes neurais PMC é denominado *backpropagation* ou retropropagação do erro [16].




Fig. 2. Fases de treinamento da rede PMC.

O processo de treinamento de redes PMC utilizando o algoritmo *backpropagation*, conhecido também como regra Delta generalizada, é comumente realizado mediante as

aplicações sucessivas de duas fases bem específicas. A ilustração de tais fases é apresentada na Fig. 2, em que é considerada uma configuração PMC constituída de duas camadas escondidas, compostas de  $n$  sinais em sua camada de entrada, tendo ainda  $n_1$  neurônios na primeira camada neural escondida,  $n_2$  neurônios da segunda camada neural escondida e  $n_3$  neurônios na camada neural de saída [16].

A primeira fase a ser aplicada é denominada de “propagação adiante” (*forward*), na qual os sinais  $\{x_1 \ x_2 \ \dots \ x_n\}$  de uma amostra no conjunto de treinamento são inseridos nas entradas da rede e são propagados camada a camada até a produção das respectivas saídas. Portanto, a aplicação dessa fase tão somente obter a saída da rede, levando-se em consideração apenas os valores atuais de pesos sinápticos e limiares de seus neurônios, os quais permanecerão inalterados durante cada execução dessa fase.

Em seguida, as respostas produzidas pelas saídas da rede são comparadas com as respectivas respostas desejadas que estão disponíveis, pois, conforme mencionado anteriormente, trata-se de um processo de aprendizado supervisionado. Considerando-se uma rede PMC constituída de  $n_3$  neurônios em sua camada de saída, os respectivos  $n_3$  desvios (erros) entre as respostas desejadas e aquelas fornecidas pela rede são então calculados, os quais serão utilizados para ajustar os pesos e limiares de todos os seus neurônios.

Em sequência, em função desses valores de erro, aplica-se a segunda fase do método *backpropagation*, denominada “propagação reversa” (*backward*). Diferentemente da fase anterior, as alterações (ajustes) dos pesos sinápticos e limiares de todos os neurônios da rede são executadas no decorrer dessa fase. Em resumo, as aplicações sucessivas das fases *forward* e *backward* fazem com que os pesos sinápticos e limiares dos neurônios se ajustem automaticamente em cada iteração, implicando-se na gradativa diminuição da soma dos erros produzidos pelas respostas da rede frente àquelas desejadas [15].

Torna-se relevante ressaltar que os ajustes das matrizes de pesos são realizados somente na fase de treinamento da rede, em que se aplicam os passos *forward* e *backward* a fim de proceder a eventuais correções sinápticas necessárias. Já na fase de operação, nenhum tipo de ajuste é realizado nos parâmetros internos da rede, sendo que, para esta ocasião, somente a fase *forward* é processada com o objetivo de gerar as saídas da rede [11]. Além do algoritmo *backpropagation* descrito acima, existem diversas variações do método para tornar o processo de convergência mais eficiente. Entre tais aperfeiçoamentos, tem-se o método de inserção do termo de *momentum*, o *resilient-propagation* e o método de Levenberg-Marquardt [15].

#### IV. TREINAMENTO E VALIDAÇÃO DA REDE NEURAL

Utilizou-se a *toolbox* de rede neural presente na ferramenta computacional MATLAB® para as etapas de treinamento e validação das oito topologias avaliadas [17]. Todas as topologias testadas possuem uma camada oculta, cuja função de ativação é tangente hiperbólica e uma camada de saída, cuja função de ativação é linear. A única diferença entre as redes PMC avaliadas reside no número de neurônios na

camada oculta. Todas as topologias utilizam duas entradas normalizadas  $[-1, 1]$ : MAV e WL. Todas as topologias possuem somente uma saída normalizada:  $[0, 1]$ .

Portanto, a rede neural deve classificar a intenção de movimento do braço e antebraço baseada no comportamento dos vetores de características MAV e WL. Vale ressaltar que o classificador neural projetado consiste em duas redes PMC em paralelo, onde cada uma possui duas entradas (MAV e WL do músculo Bíceps ou MAV e WL do músculo Flexor Superficial dos Dedos) e uma saída (contração e relaxamento do músculo Bíceps ou contração e relaxamento do músculo Flexor Superficial dos Dedos). Uma rede é responsável por identificar a intenção de movimento do músculo Bíceps e a outra rede é responsável por identificar a intenção de movimento do músculo Flexor Superficial dos Dedos. O treino e validação de cada rede independem um do outro.

Utilizaram-se 200 dados de entrada e saída do músculo Bíceps e 200 dados de entrada e saída do músculo Flexor Superficial dos Dedos aquisitados do segundo autor para o treinamento e validação das redes PMC. Por sua vez, utilizaram-se 200 dados de entrada e saída do músculo Bíceps e 200 dados de entrada e saída do músculo Flexor Superficial dos Dedos aquisitados do primeiro autor para a etapa de teste das redes já treinadas. Os dados utilizados neste trabalho constituem uma pequena parcela do banco de dados oriundo do Trabalho de Conclusão de Curso (TCC) do segundo autor e não está disponível publicamente [18]. O algoritmo de Levenberg-Marquardt foi utilizado na fase de aprendizado do classificador neural. Na Tab. 1 são apresentadas as possíveis saídas do classificador com suas respectivas interpretações (*status*) de ambos os músculos analisados.

Tabela 1. Correspondência entre as saídas do classificador neural e o estado do músculo.

Saída do classificador neural	Interpretação ( <i>status</i> )
$y = [0 \ 0]^T$	Bíceps e Flexor Superficial dos Dedos relaxados
$y = [0 \ 1]^T$	Bíceps relaxado e Flexor Superficial dos Dedos contraído
$y = [1 \ 0]^T$	Bíceps contraído e Flexor Superficial dos Dedos relaxado
$y = [1 \ 1]^T$	Bíceps e Flexor Superficial dos Dedos contraídos

Cada interpretação muscular pode corresponder a um movimento isolado ou à ocorrência de movimentos simultâneos. Quando os dois músculos se encontram relaxados significa que o antebraço está estendido ( $180^\circ$  com o braço) e os dedos abertos e alinhados com a palma da mão. Caso apenas o Bíceps esteja contraído, há então a flexão do antebraço com os dedos abertos. Se somente o Flexor Superficial dos Dedos estiver em contração, então os dedos estão em adução com o antebraço estendido. Caso o classificador acuse ambos os músculos em contração, tem-se a flexão do antebraço juntamente com a adução dos dedos.

Na Tab. 2 são apresentados os resultados obtidos de Erro Médio Quadrático (EMQ) para quatro topologias (1, 3, 5 e 7 neurônios na camada oculta) referentes à rede responsável

pelos vetores de características do Bíceps, tanto para os dados de treinamento quanto para os de validação.

Na Tab. 3 são apresentados os resultados obtidos de EMQ para quatro topologias (1, 3, 5 e 7 neurônios na camada oculta) referentes à rede responsável pelos vetores de características do Flexor Superficial dos Dedos, tanto para os dados de treinamento quanto para os de validação. O índice EMQ é a métrica escolhida neste trabalho para se avaliar qual topologia de rede PMC melhor aprendeu a mapear os dados de entrada para os dados de saída desejados pelos projetistas. EM geral, quanto menor o EMQ calculado, mais bem treinada está a rede neural em questão. A quantidade de épocas de treinamento necessária via retropropagação do erro foi igual ou inferior a 24 épocas para ambas as redes.

Tabela 2. EMQ após treino das redes (Bíceps).

Topologia	Treinamento	Validação
1 Neurônio	$2,7891 \times 10^{-13}$	$1,1148 \times 10^{-7}$
3 Neurônios	$3,1727 \times 10^{-13}$	$1,3431 \times 10^{-7}$
5 Neurônios	$3,2887 \times 10^{-13}$	$1,0997 \times 10^{-7}$
7 Neurônios	$6,2431 \times 10^{-14}$	$3,8571 \times 10^{-8}$

Tabela 3. EMQ após treino das redes (Flexor Superficial dos Dedos).

Topologia	Treinamento	Validação
1 Neurônio	$2,4187 \times 10^{-13}$	$1,0094 \times 10^{-17}$
3 Neurônios	$3,2906 \times 10^{-13}$	$1,9462 \times 10^{-14}$
5 Neurônios	$2,2493 \times 10^{-13}$	$3,5686 \times 10^{-14}$
7 Neurônios	$3,3909 \times 10^{-14}$	$2,2967 \times 10^{-14}$

Baseando-se nos resultados disponibilizados nas Tab. 2 e Tab. 3, todas as próximas simulações numéricas serão realizadas com a rede PMC com somente um neurônio na camada oculta de ambas as redes, pois essa topologia é menos complexa, possui maior poder de mapeamento de dados de entrada e saída e uma ótima capacidade de generalização para diferentes valores de MAV e WL. O classificador neural selecionado dentre as oito topologias possíveis também apresentou bons resultados nos testes da próxima seção.

## V. RESULTADOS

A arquitetura selecionada possui as seguintes matrizes de pesos sinápticos da camada escondida  $W_1$  e camada de saída  $W_2$  da rede 1, assim como o vetor de *bias* da camada escondida  $b_1$  e de saída  $b_2$ :

$$\begin{aligned} W_1 &= [-57,6830 \quad -42,1013] \\ W_2 &= -1 \\ b_1 &= -33,0167 \\ b_2 &= 0 \end{aligned} \quad (3)$$

Enquanto para a rede 2, as matrizes de pesos sinápticos da camada escondida  $W_3$  e camada de saída  $W_4$  e o vetor de *bias* da camada escondida  $b_3$  e de saída  $b_4$  são:

$$\begin{aligned} W_3 &= [144,9343 \quad 68,0979] \\ W_4 &= 1 \\ b_3 &= 1,56,0925 \\ b_4 &= 0 \end{aligned} \quad (4)$$

Tal arquitetura é usada para indicar a intenção de movimento do braço e antebraço de um usuário a partir dos

vetores de características MAV e WL de cada músculo. O tempo de resposta do classificador neural é igual a 20 ms, ou seja, a cada instante de tempo de 20 ms o classificador informa a intenção de movimento do usuário. Na Fig. 3 é apresentada a resposta do classificador neural para os dados de entrada do Bíceps usados na etapa de treinamento e validação da rede 1.

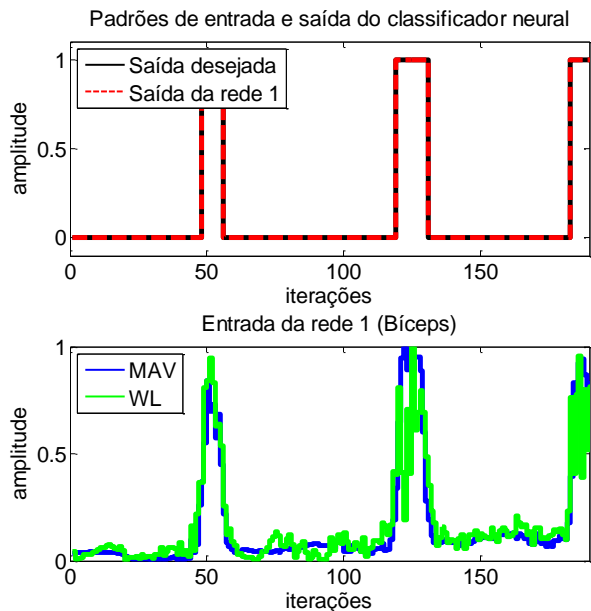


Fig. 3. Resposta do classificador neural (rede 1).

Já na Fig. 4 é apresentada a resposta do classificador neural para os dados de entrada do Flexor Superficial dos Dedos usados na etapa de treinamento e validação da rede 2.

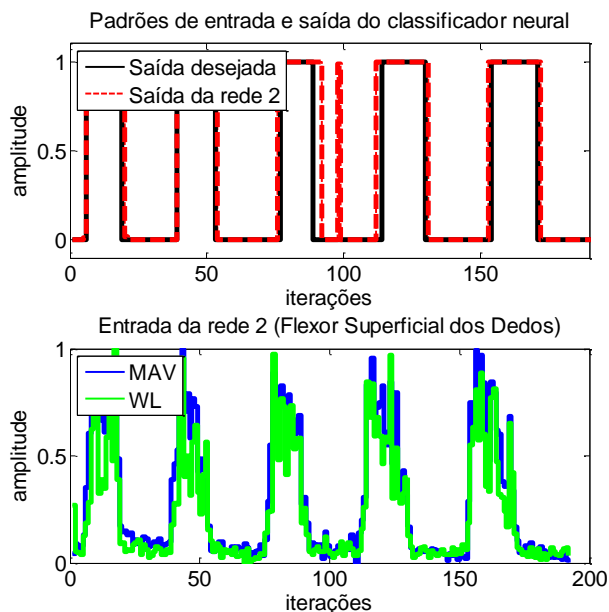


Fig. 4. Resposta do classificador neural (rede 2).

Na Fig. 5 é apresentada a resposta do classificador neural para os dados de entrada do Bíceps usados na etapa de teste da rede 1 já treinada e, por sua vez, na Fig. 6 é apresentada a resposta do classificador neural para os dados de entrada do

Flexor Superficial dos Dedos usados na etapa de teste da rede 2 selecionada. Na Tab. 4 é listado o EMQ existente entre a saída desejada e a saída do classificador neural para cada músculo a cada 20 milissegundos, de forma a indicar o movimento ou inércia do braço e antebraço do usuário.

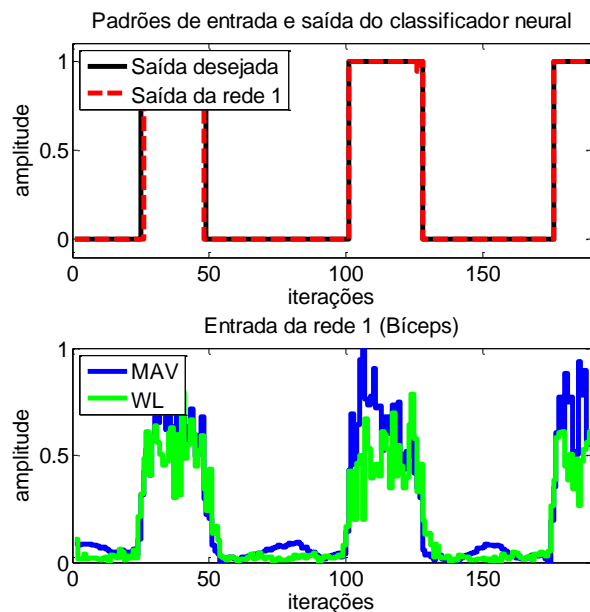


Fig. 5. Resposta do classificador neural (rede 1).

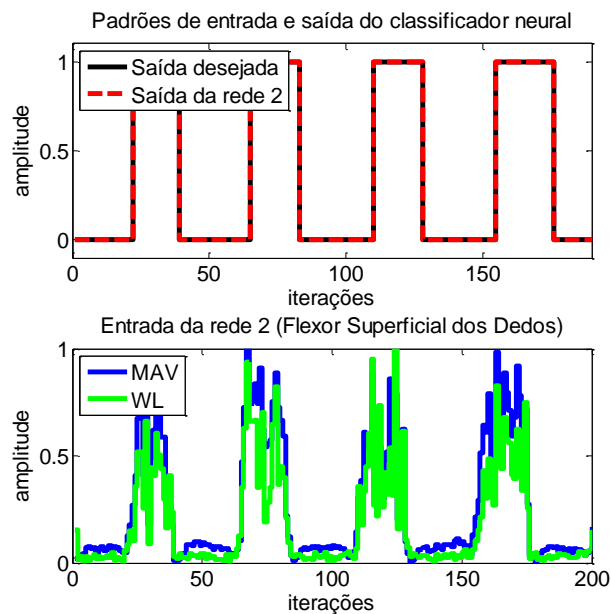


Fig. 6. Resposta do classificador neural (rede 2).

Tabela 4. Resultados para os casos simulados.

Caso simulado	EMQ do classificador neural
Teste 1	$6,2360 \times 10^{-2}$
Teste 2	$1,4991 \times 10^{-2}$

## VI. CONCLUSÃO

Este artigo apresentou uma rede neural aplicada à intenção de movimento de dois grupos musculares distintos, localizados no braço e antebraço do usuário. Os dados de

treinamento e validação da rede foram extraídos a partir dos sinais mioelétricos obtidos do segundo autor, enquanto os dados de teste utilizados foram providos pelo primeiro e segundo autor, de modo que os dados de teste são diferentes dos dados de treinamento e validação. Após seu treinamento, a rede apresentou boa capacidade de generalização, como pode ser visto nas Tabelas 2, 3 e 4.

O classificador neural disponibiliza sua saída a cada 20 milissegundos, pois este é o intervalo de tempo necessário para processar o conjunto de dados de entrada do mesmo, ou seja, a cada período de tempo igual a 20 ms, o classificador neural fornece uma saída indicando se o grupo de músculos monitorados está em repouso ou contraído, no caso apresentado, os músculos monitorados são o Bíceps e o Flexor Superficial dos Dedos. Diante do exposto, conclui-se que, o classificador neural proposto é capaz de discriminar de maneira bastante satisfatória a intenção de movimento muscular do usuário a partir dos índices MAV e WL.

#### AGRADECIMENTOS

O autores agradecem ao apoio financeiro do Programa de Pós-Graduação em Engenharia Elétrica (PPGEE) da Universidade Federal do Pará (UFPA), ao CNPq e a CAPES.

#### REFERÊNCIAS

- [1] L. R. Ortolan. Estudo e Avaliação de Técnicas de Processamento do Sinal Mioelétrico para o Controle de Sistemas de Reabilitação. São Carlos, 2002. Dissertação de Mestrado – Departamento de Engenharia Elétrica da Escola de Engenharia de São Carlos – Universidade de São Paulo.
- [2] M. R. Ahsan; M. I. Ibrahimy; O. O. E. Khalifa. The Use of Artificial Neural Networks in the Classification of EMG Signals. In *Third FTRA International Conference on Mobile, Ubiquitous and Intelligent Computing*, p.225-229, 2012.
- [3] F. E. R. Mattioli; D. S. D. Caetano; W. Gomes; E. A. Lamounier. Utilização de Redes Neurais para a Classificação de Sinais EMG Aplicados no Controle de Próteses Virtuais de Mão. Disponível em: < <http://www.lbd.dcc.ufmg.br/colecoes/wrva/2010/0040.pdf>>. Acesso em: 12 dez. 2017.
- [4] E. L. Ferreira; M. M. Gouvêa. Sistema Neural para Reconhecimento de Padrões em Sinais EMGs para Controle de Braço Robótico. Em *XIII Encontro Nacional de Inteligência Artificial e Computacional*, p.505-515, 2016.
- [5] M. Hakonen; H. Piitulainen; A. Visala. Current State of Digital Signal Processing in Myoelectric Interfaces and Related Applications. In *Biomedical Signal Processing and Control*, v.18, p.334-359, 2015.
- [6] A. C. Guyton; J. E. Hall. Tratado de Fisiologia Médica. 11ª edição, Elsevier: Rio de Janeiro, 2006.
- [7] P. E. Barkhaus; S. D. Nandedkar. EMG Evaluation of the Motor Unit - Electrophysiologic Biopsy. Medscape, 2015.
- [8] R. C. Aguiar. Myoelectric Prosthesis – Modelization and Control of a Bionic Arm. Porto, 2015. Dissertação de Mestrado. Faculdade de Engenharia da Universidade do Porto – Universidade do Porto.
- [9] M. Zecca; S. Micera; M. C. Carrozza; P. Dario. Control of Multifunctional Prosthetic Hands by Processing the Electromyographic Signal. In *Critical Reviews™ in Biomedical Engineering*, p.459-485, 2002.
- [10] J. Ma; N. V. Thakor; F. Matsuno. Hand and Wrist Movement Control of Myoelectric Prosthesis Based on Synergy. In *IEEE Transactions on Human-Machine Systems*, v.45, n.1, p.73-84, 2015.
- [11] S. Haykin. Neural Networks: A Comprehensive Foundation. Upper Prentice Hall: Saddle River, 1999.
- [12] L. M. L. Campos; A. S. Lima. “Evaluating the Learning of Automata through the use of Recurrent Neural Networks”, *IEEE Latin America Transactions*, vol. 16, no. 10, Oct. 2019.
- [13] D. Canêdo; A. Romariz. “Intrusion Detection System in Ad Hoc Networks with Neural Networks Artificial and K-Means Algorithm”, *IEEE Latin America Transactions*, vol. 17, no. 7, July. 2019.
- [14] V. Barth; R. Oliveira; M. Oliveira; V. Nascimento. “Vehicle Speed Monitoring using Convolutional Neural Networks”, vol. 17, no. 6, June. 2019.
- [15] I. N. Silva; D. H. Spatti; R. A. Flauzino. Redes Neurais Artificiais para Engenharia e Ciências Aplicadas. Artliber: São Paulo, 2010.
- [16] D. E. Rumelhart; G. E. Hinton; R. J. Williams. Learning Representation by Error Propagation. Parallel Distributed Processing, vol. 1. MIT Press: Cambridge, 1986.
- [17] Mathworks. Neural Networks Toolbox User’s Guide. The MathWorks Inc., 2018.
- [18] G. S. Amorim. Proposta de Modelamento de Sistemas Mioelétricos para Classificação de Movimentos. Trabalho de Conclusão de Curso – Instituto de Tecnologia – Universidade Federal do Pará, Belém, 2018.



**Luís Augusto Mesquita de Castro** é graduado (2015) em Engenharia de Controle e Automação pelo Instituto Federal de Educação, Ciência e Tecnologia do Pará (IFPA). Possui Mestrado (2018) em Engenharia Elétrica pela Universidade Federal do Pará (UFPA). Atualmente é aluno de doutorado em Engenharia Elétrica pela Universidade Federal do Pará, atuando principalmente nas áreas: Modelagem e Identificação de Sistemas; Redes Neurais Artificiais; Lógica e Controle Fuzzy; Algoritmos Evolucionários; Controle Digital; Controle Adaptativo; Controle Preditivo; Controle Estocástico; Controle Robusto com aplicações em Processos Industriais, Sistemas Elétricos de Potência e Sistemas Biomecânicos.



**Gabriela Souza de Amorim** é graduada (2018) em Engenharia Biomédica pela Universidade Federal do Pará. Atualmente é aluna de mestrado em Engenharia Elétrica pela Universidade Federal do Pará, estando vinculada ao Laboratório de Controle e Sistemas (LACOS). Seus principais interesses de pesquisa são: teoria de controle, identificação de sistemas, filtragem digital e redes neurais artificiais aplicadas na área de engenharia biomédica e controle de processos.



**Bruno Gomes Dutra** é graduado (2014) em Engenharia de Controle Automação pelo Instituto de Estudos Superiores da Amazônia (IESAM). Possui Mestrado (2018) em Engenharia Elétrica pela Universidade Federal do Pará. Atualmente é aluno de doutorado em Engenharia Elétrica pela Universidade Federal do Pará, atuando principalmente nos seguintes temas: controle de sistemas, controle preditivo, filtro de Kalman, fusão sensorial, eletromiografia, instrumentação e biomédica.



**Antonio da Silva Silveira** é professor doutor Adjunto do Instituto de Tecnologia (ITEC) da Universidade Federal do Pará atuando na área de Controle de Sistemas Dinâmicos no Laboratório de Controle e Sistemas (LACOS). Dentre as linhas de pesquisa de interesse destacam-se as seguintes: Controle Preditivo Estocástico; Controle Robusto; Controle Adaptativo; Aplicações em Controle de Sistemas Aeroespaciais.